



### 3. 信号的统计检测理论

#### ① 贝叶斯准则:

先验概率  $P(H_i)$  已知, 代价因子  $C_{ij}$  给定, 使平均代价  $C$  最小.

$$\frac{P(X|H_1)}{P(X|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P(H_0)(C_{10}-C_{00})}{P(H_1)(C_{01}-C_{11})} \quad \text{对数}$$

性能分析  $\rightarrow P(H_1|H_0) \quad P(H_1|H_1)$

a. 由检测统计量概率分布得出

b. 利用公式:

$$P(H_1|H_0) = Q\left[\frac{\ln \eta}{d} + \frac{d}{2}\right] \quad Q(X) = \int_X \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$$

$$P(H_1|H_1) = Q\left[\frac{\ln \eta}{d} - \frac{d}{2}\right]$$

$$\text{单发: } d^2 = \frac{A^2}{\sigma_n^2}, \quad \text{匹配: } d^2 = \frac{NA^2}{\sigma_n^2}$$

#### ② 维生贝叶斯:

a. 最小平均错误概率准则. MAEP

$$C_{00} = C_{11} = 0, \quad C_{10} = C_{01} = 1.$$

b. 最大似然准则. ML.

$$P(H_0) = P(H_1) = 1/2, \quad C_{00} = C_{11} = 0, \quad C_{10} = C_{01} = 1.$$

c. 最大后验概率准则.

$$C_{10} - C_{00} = C_{01} - C_{11}$$

$$P(H_1|X) \underset{H_0}{\overset{H_1}{\geq}} P(H_0|X)$$

d. 极小化极大准则.

给定代价因子  $C_{ij}$ , 无法再确定先验概率  $P(H_i)$

避免产生过大的代价, 使极大可能的代价极小化.





猜测一个先验概率  $P_i$ , 确定门限  $\eta$  以此判决.

$$C_{00} = C_{11} = 0$$

$$\Rightarrow C_{01} P_M(P_i^*) - C_{10} P_F(P_i^*) = 0$$

$\frac{P(H_0|H_1)}{P(H_1|H_0)}$  调整  $\frac{P(H_1|H_0)}{P(H_0|H_1)}$  调整

c: 奈曼-皮尔逊准则.

不能预知  $P(H_j)$  和  $C_{ij}$ .

使  $P(H_1|H_0)$  尽可能小,  $P(H_1|H_1)$  尽可能大 ( $\Rightarrow P(H_0|H_1) \downarrow$ ).

N-P准则: 在  $P(H_1|H_0) = \alpha$  条件下, 使  $P(H_1|H_1)$  最大.

对观测空间划分.

③ 信号统计检测的性能.

$$d^2 = \frac{(E[\tilde{e}|H_0] - E[\tilde{e}|H_1])^2}{\text{Var}[\tilde{e}|H_0]}$$

④ M元信号检测. (统计检测).

a. 贝叶斯:

$$I_2(x) = \sum_{j=0}^{M-1} P(H_j) (C_{ij} - C_{jj}) P(x|H_j)$$

$$i = \min_j I_2(x) \rightarrow H_i$$

b. 最小平均错误概率.

$P(H_j)$  已知,  $C_{ii} = 0$   $C_{ij} = 1$ .

$$I_2(x) = \sum_{j=0}^{M-1} P(H_j) P(x|H_j)$$

$$\min_{i \neq j} I_2(x)$$

若  $P(H_j) = \frac{1}{M} = P$

$$I_2(x) = \sum_{j=0}^{M-1} P(x|H_j) P = \left[ \sum_{j=0}^{M-1} P(x|H_j) - P(x|H_i) \right] P$$

$$\Rightarrow \max P(x|H_i)$$







## ⑤ 参量信号的统计检测

接收信号的概率密度函数含有未知参量.

a. 广义似然比检验 (相干检测).

$$p(x|\theta_0; H_0), p(x|\theta_1; H_1)$$

先用最大似然估计 (使  $p(x|\theta_j; H_j)$  最大的  $\theta_j$ )  $\rightarrow \hat{\theta}_{jml}$ .

转化为确定信号的统计检测.

b. 贝叶斯方法 (非相干检测)

利用或猜测  $\theta_j$  的统计特性 ~~进行~~.

如由  $p(\theta_j) \rightarrow p(x|H_j)$ .

或采用  $N-P$  准则.

## ⑥ 信号的序列检测.

观测  $N$  次后立即判决  $\rightarrow$  硬判决.

边观测边判决  $\rightarrow$  硬判决.

$$\lambda(\vec{x}_k) \geq \eta_1 \rightarrow H_1$$

$$\lambda(\vec{x}_k) \leq \eta_0 \rightarrow H_0$$

$$\eta_0 < \lambda(\vec{x}_k) < \eta_1 \text{ 不判决}$$

$$\lambda(\vec{x}_N) = \lambda(x_N) \lambda(\vec{x}_{N-1})$$

$$\eta_1 = \frac{1-\beta}{\alpha} \quad \eta_0 = \frac{\beta}{1-\alpha}$$

## ⑦ 一般高斯信号的统计检测 (各次观测之间不独立)

$$Cov(x) = E[(x - \mu_x)(x - \mu_x)^T] = \vec{C}_x \quad E(x) = \mu_x$$

$$p(x) = \frac{1}{(2\pi)^{N/2} |\vec{C}_x|^{1/2}} \exp\left[-\frac{1}{2}(x - \mu_x)^T \vec{C}_x^{-1} (x - \mu_x)\right]$$





#### 4. 信号波形的检测.

① 匹配滤波器: MF

SNR 定, 使输出功率信噪比最大.

~~SNR~~:

实信号:  $h(t) = k s(t_0 - t)$

$$h(t) = k s^*(t_0 - t)$$

$$H(\omega) = S^*(\omega) e^{-j\omega t_0}$$

$$SNR_0 = \frac{2P_s}{N_0} = \frac{1}{2\pi} \int_{-\infty}^{\infty} \frac{|S(\omega)|^2}{P_n(\omega)} d\omega$$



$t = T$  时刻, 与相关器输出相等

对时延具有选择性, 对频移信号不具有选择性.

#### (2). 随机过程的正交级数展开.

样本  $x_k$  之间相关.

正交函数集  $\rightarrow$  完备正交函数集  $\{f_k(t)\}$ .

$$x_k = \int_0^T x(t) f_k(t) dt \quad x_k \text{ 可能相关 (协方差不为0)}$$

a. 卡亨南-洛维展开

根据噪声干扰的特性 选择  $\{f_k(t)\}$

$$Z(x_k) = \int_0^T s(t) f_k(t) dt = s_k$$

$$\text{希望, } E[(x_j - s_j)(x_k - s_k)] = \lambda_k \delta_{jk}$$

$$\Rightarrow \int_0^T \gamma_n(t-u) f_k(u) du = \lambda_k f_k(t) \quad 0 \leq t \leq T$$

$$E[n(t)n(u)] = \gamma_n(t-u)$$





$\rho$  为独立  $p(x, y) = p(x)p(y)$ . 独立  $\Rightarrow$  不相关



白噪声.  ~~$\frac{N_0}{2}$~~   $r_n(t-u) = \frac{N_0}{2} \delta(t-u)$

$$E[(x_j - s_j)(x_k - s_k)] = \frac{N_0}{2} \delta_{jk}$$

对任意正交函数集  $\{s_k(t)\}$  展开, 如都不相关.

高斯分布  $\Rightarrow$  独立.

### ③ 高斯白噪声中确知信号波形的检测

a.  $x_k, s_k, n_k$ .

$x_k$  独立.

$$\Rightarrow E(x_k | H_j) \quad \text{Var}(x_k | H_j)$$

$$\Rightarrow p(x_k | H_j)$$

$$\Rightarrow p(\vec{x}_N | H_j) = \frac{p(\vec{x}_N | H_1)}{\sum_{i=1}^M p(\vec{x}_N | H_i)}$$

$$\Rightarrow \lambda(x_N) = \frac{p(x_N | H_1)}{p(x_N | H_0)} \sum_{i=1}^M \eta_i$$

$$\Rightarrow N \rightarrow \infty \quad \ln[x(t)] = \lim_{N \rightarrow \infty} [\ln \lambda(x_N)]$$

$\Rightarrow$  系统结构. (相关, 匹配)

$$\Rightarrow \text{性能分析: } E[L | H_j] \quad \text{Var}(L | H_j)$$

$$\Rightarrow p(L | H_j) \quad \text{或由 } d^2$$

$x_k$  无限维.

b. 充分统计量.

$x_k$  有限维.

$$\text{构造 } f_1(t) = \frac{1}{\sqrt{E_s}} s(t) \quad 0 \leq t \leq T$$

$$\Rightarrow H_0: x_1 = \eta_1$$

$$x_k = \eta_k \quad k \geq 2$$

$$H_1: x_1 = \sqrt{E_s} + \eta_1$$

$$x_k = \eta_k \quad k \geq 2 \quad f_k(t) \text{ 与 } s(t) \text{ 正交}$$

$x_1$  是一个充分统计量

$$\lambda(x_1) = \frac{p(x_1 | H_1)}{p(x_1 | H_0)} \sum_{i=1}^M \eta_i$$

YI SHANG





C. 一般二元:

正交信号展开

最佳信号波形设计

$$d^2 \text{ 增大 } Z_{s_0} + Z_{s_1} = 2Z_s$$

$$\text{正交信号 } -s_0(t) = s_0(t) \text{ 最大 } d^2 = \frac{8Z_s}{\eta_0}$$

例1,  $d^2 \rightarrow 0$  正交信号

$$d^2 = \frac{4Z_s}{\eta_0}$$

充分统计量:

$$f_1(t) = \frac{1}{\sqrt{Z_{s_1}}} s_1(t)$$

$$g_2(t) = s_0(t) - \int_0^T s_0(t) f_1(t) dt f_1(t)$$

$$f_2(t) = \frac{g_2(t)}{\sqrt{\int_0^T g_2^2(t) dt}}$$

例3. 复信号的统计检测

$$H_0: \tilde{x}_k = \tilde{n}_k \quad k=1, 2, \dots, N. \quad \tilde{n}_k \sim \mathcal{CNC}(0, \sigma_n^2)$$

$$H_1: \tilde{x}_k = s_k + \tilde{n}_k \quad \tilde{x} = (\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_N)^T$$

$$p(\tilde{x} | H_1) = \frac{1}{(2\pi\sigma_n^2)^N} \exp \left[ -\frac{1}{2\sigma_n^2} (\tilde{x} - \tilde{s})^H (\tilde{x} - \tilde{s}) \right]$$

三处不同(无2). ~~无~~

$$(\tilde{x}^H \tilde{s})^* = \tilde{s}^H \tilde{x} \quad \tilde{x}^H \tilde{s} + \tilde{s}^H \tilde{x} = \text{Re}(\tilde{s}^H \tilde{x})$$

$$\sin^2 \omega_0 t = \frac{1 - \cos 2\omega_0 t}{2}$$







## 5. 信号的统计估计理论.

被估计量  $\theta$     观测量  $x$     估计量  $\hat{\theta}$ .

估计量

均值  $E[\hat{\theta}(x)]$

均方误差:  $E[\hat{\theta}(x)^2]$

误差  $\hat{\theta}(x) = \theta - \hat{\theta}(x)$

### ① 随机变量的贝叶斯估计. (随机变量)

先验  $p(\theta)$  已知

a. 最小均方误差估计. (误差平方代价函数)

$$C(\hat{\theta}) = (\theta - \hat{\theta})^2$$

$$\text{条件均值. } \hat{\theta}_{mse} = \int_{-\infty}^{\infty} \theta p(\theta|x) d\theta = \frac{\int_{-\infty}^{\infty} \theta \bar{p}(x|\theta) p(\theta) d\theta}{\int_{-\infty}^{\infty} \bar{p}(x|\theta) p(\theta) d\theta} = \bar{p}(x)$$

b. 条件中值估计 (误差绝对值代价函数) med.

$$C(\hat{\theta}) = |\theta - \hat{\theta}|$$

$$\int_{-\infty}^{\infty} p(\theta|x) d\theta = \int_{-\infty}^{\infty} p(\theta|x) dx$$

c. 最大后验估计. (均匀代价函数)

$$C(\hat{\theta}) = \begin{cases} 1, & |\hat{\theta}| \geq \frac{a}{2} \\ 0, & |\hat{\theta}| < \frac{a}{2} \end{cases}$$

$$\text{对 } \frac{2p(\theta|x)}{2\theta} \bigg|_{\theta=\hat{\theta}_{map}} = 0$$

~~不具有~~ 最佳估计的不变性:

$p(\theta|x)$  高斯,  $\rightarrow$  估计量一样  $\rightarrow$  等于最小均方误差估计量.

(1):  $C(\hat{\theta})$  对称, 下凸.  $p(\theta - \hat{\theta}_{mse}|x) = p(\hat{\theta}_{mse} - \theta|x)$  关于  $\hat{\theta}_{mse}$  对称

(2):  $C(\hat{\theta})$  对称 非降(0). 关于  $\hat{\theta}_{mse}$  对称单峰.

### (2) 最大似然估计.





② 最大似然估计. (非随机参量或  $p(\theta)$  未知)

取  $p(x|\theta) dx$  最大的  $\theta$  做为估计量  $\hat{\theta}_{ml}$

$$\frac{\partial p(x|\theta)}{\partial \theta} \bigg|_{\theta=\hat{\theta}_{ml}} = 0$$

不变性:

$a = g(\theta)$   $a$  与  $\theta$  一对变换

$\Rightarrow \hat{a}_{ml} = g(\hat{\theta}_{ml})$  (不一定无偏)

③ 估计量的性质:

a. 无偏性:

$E(\hat{\theta}) = \theta$  或  $E(\hat{\theta}) = E(\theta)$  无偏 (否则有偏)

$\lim_{n \rightarrow \infty} E[\hat{\theta}(x_n)] = \theta$  或  $E[\theta]$  渐近无偏 (有偏)

b. 有效性:

均方误差  $E[(\theta - \hat{\theta})^2]$  最小

c. 一致性: 观测次数  $n$  误差  $\downarrow$

$$\lim_{n \rightarrow \infty} P[|\theta - \hat{\theta}(x_n)| > \varepsilon] = 0 \quad \text{或} \quad \lim_{n \rightarrow \infty} E[(\theta - \hat{\theta}(x_n))^2] = 0$$

d. 充分性:

$$p(x|\theta) = g(\hat{\theta}(x)|\theta)h(x).$$

④ 克拉美-罗 (界, 不等式)

a. 非随机参量:

$$\text{Var}(\hat{\theta}) = E[(\theta - \hat{\theta})^2] \geq \frac{1}{E\left[\left(\frac{\partial \ln p(x|\theta)}{\partial \theta}\right)^2\right]} = -\frac{1}{E\left[\frac{\partial^2 \ln p(x|\theta)}{\partial \theta^2}\right]}$$

$$\frac{\partial \ln p(x|\theta)}{\partial \theta} = (\theta - \hat{\theta})k(\theta) \Rightarrow \text{有效}.$$

$$\Rightarrow \hat{\theta} = \hat{\theta}_{ml}$$

b. 随机参量:

$$\text{Var} = \frac{1}{I(\theta)}$$







联合估计 / 估计

CMA

EDCA

$$E[(\theta - \hat{\theta})^2] \geq \frac{1}{E\left[\left(\frac{\partial \ln p(x|\theta)}{\partial \theta}\right)^2\right]} \geq \frac{1}{-E\left[\frac{\partial^2 \ln p(x|\theta)}{\partial \theta^2}\right]}$$

$$\frac{\partial \ln p(x|\theta)}{\partial \theta} = (\theta - \hat{\theta})k, \quad k: \text{任意非0常数.}$$

$$\Rightarrow \text{有效} \Rightarrow \hat{\theta} = \hat{\theta}_{\text{map}} - \frac{1}{k}$$

C. 非随机变量(参数)估计.

$$\text{先验} \Delta E[\hat{a}] = a = g(\theta) \Rightarrow \text{Var}(\hat{a}) \geq \frac{\left(\frac{\partial g(\theta)}{\partial \theta}\right)^2}{E\left[\left(\frac{\partial \ln p(x|\theta)}{\partial \theta}\right)^2\right]} \geq \dots$$

$$\frac{\partial \ln p(x|\theta)}{\partial \theta} = (a - \hat{a})k(\theta).$$

⑤ 矢量估计.

a. 最小均方误差.

克拉美界.

$$\hat{\theta}_{\text{mse}} = \int \hat{\theta} p(\hat{\theta}|\mathbf{x}) d\hat{\theta}$$

$$J = -E\left[\frac{\partial^2 \ln p(x|\theta)}{\partial \theta_i \partial \theta_j}\right]$$

b. 最大后验估计.

$$E[\theta - \hat{\theta}] \geq J^{-1}$$

$$\left. \frac{\partial \ln p(\theta|\mathbf{x})}{\partial \theta} \right|_{\theta = \hat{\theta}_{\text{map}}} = 0$$

$$\leq \frac{\partial \ln p(x|\theta)}{\partial \theta} = -J(\theta - \hat{\theta}) \text{ (有效)}$$

c. 最大似然估计.

随机矢量同样

$$\left. \frac{\partial \ln p(x|\theta)}{\partial \theta} \right|_{\theta = \hat{\theta}_{\text{ml}}} = 0$$

$$\text{协方差矩阵} \mathbf{M} = E[(\theta - \hat{\theta})(\theta - \hat{\theta})^T]$$

⑥ 线性最小均方误差估计.

元  $x, \theta$  的概率密度函数. 只有  $x, \theta$  的前两阶矩.

$\Rightarrow$  均方误差最小,  $\hat{\theta}$  是  $x$  的线性函数.

$$x = H\theta + n \quad \hat{\theta} = a + Bx \quad \text{minimize } E[(\theta - \hat{\theta})^T (a - \hat{\theta})]$$

$$\hat{\theta}_{\text{mse}} = \mathbf{H}_0 + \mathbf{C}_{\theta x} \mathbf{C}_x^{-1} (\mathbf{x} - \mathbf{H}_x)$$

$$a = \mathbf{H}_0 - \mathbf{B} \mathbf{H}_x \quad \mathbf{B} = \mathbf{C}_{\theta x} \mathbf{C}_x^{-1}$$

YI SHANG



由 扫描全能王 扫描创建



性质: a. 线性函数, b. 无偏.

c. 均方误差最小.

$$M_{\text{MSE}} = E[(\theta - \hat{\theta}_{\text{MSE}})(\theta - \hat{\theta}_{\text{MSE}})^T] = C_{\theta} - C_{\theta X} X^T C_{\theta X}^{-1} X^T C_{\theta X}$$

d. 正交性.

$$E[(\theta - \hat{\theta}_{\text{MSE}}) X^T] = 0 \quad \text{误差向量与观测向量正交} \quad \text{证明: 引入 } E[(\theta - \hat{\theta}_{\text{MSE}}) X^T] = 0$$

$\hat{\theta}_{\text{MSE}}$  是  $\theta$  在  $X^T$  上的正交投影

### ① 最小二乘估计.

无先验知识, 只有观测信号模型  $\rightarrow$  误差平方和最小

线性:  $X = H\theta + n_k$  误差平方和:  $J(\theta) = (X - H\theta)^T (X - H\theta)$

$$\hat{\theta}_{\text{LS}} = (H^T H)^{-1} H^T X$$

最小二乘估计误差

$$J_{\min}(\hat{\theta}_{\text{LS}}) = X^T [I - H(H^T H)^{-1} H^T] X$$

不是均方误差

加权:  $\hat{\theta}_{\text{LSW}} = (H^T W H)^{-1} H^T W X$

$$W = C_n^{-1} \rightarrow M_{\hat{\theta}_{\text{LSW}}}$$

单参量:

$$X_k = h_k \theta + n_k \quad H = (h_1, h_2, \dots, h_N)^T$$

$$\hat{\theta}_{\text{LS}} = \frac{\sum_{k=1}^N h_k X_k}{\sum_{k=1}^N h_k^2}$$

$$\text{均方误差 } \sigma_{\hat{\theta}_{\text{LS}}}^2 = \frac{1}{\sum_{k=1}^N h_k^2} \sigma_n^2$$

$$M_{\hat{\theta}_{\text{LS}}} =$$

### (8) 信号波形中参量的估计:

未知参量的最大似然估计:

$$\frac{\partial \ln p(X|\theta)}{\partial \theta_j} = \frac{2}{N} \int_0^T [X(t) - S(t; \theta)] \frac{\partial S(t; \theta)}{\partial \theta_j} dt = 0 \Rightarrow \hat{\theta}_{\text{ML}}$$

克拉美-罗界:

$$C_{\hat{\theta}_{\text{ML}}} \geq \frac{1}{\frac{2}{N_0} \int_0^T \left[ \frac{\partial S(t; \theta)}{\partial \theta} \right]^2 dt}$$

